

Modelos de machine learning para predecir la estancia en UCI utilizando patrones perioperatorios

*Note: Sub-titles are not captured in Xplore and should not be used

Alexander Paredes^{1,2} Eduardo Cuti^{1,2} Angel Dianderas^{1,2}.

Abstract—La medicina perioperatoria se enfoca en el cuidado de pacientes quirúrgicos en las fases preoperatoria, intraoperatoria y postoperatoria, enfrentando complicaciones impredecibles que pueden ser fatales y a menudo requieren monitoreo en UCI. Reducir riesgos es esencial, con 234 millones de cirugías mayores realizadas anualmente y 1.6 millones de muertes globales. En Perú, las cirugías abdominales tienen una alta mortalidad a corto plazo (15%-20%). La inteligencia artificial (IA) puede ayudar a predecir complicaciones postoperatorias, mejorando los resultados y reduciendo costos. Este proyecto utiliza la base de datos INSPIRE para desarrollar modelos de IA que identifiquen factores de riesgo en cirugías abdominales. La metodología incluye la selección, preprocesamiento y análisis de datos de pacientes mediante machine learning.

Index Terms—component, formatting, style, styling, insert

I. INTRODUCCIÓN

La medicina perioperatoria es una disciplina esencial que incluye el cuidado antes, durante y después de una cirugía. Las complicaciones que ocurren en el periodo postoperatorio representan un desafío significativo para el personal de salud debido a su naturaleza impredecible y pueden aparecer de manera repentina, llevando rápidamente a la muerte. Debido a estas complicaciones, muchos pacientes necesitan ser ingresados en la UCI para un monitoreo constante. [1]

Para asegurar una atención segura y minimizar los daños a los pacientes, es crucial identificar y reducir los factores de riesgo de posibles eventos adversos. Por lo tanto, es fundamental realizar una evaluación previa de las necesidades del paciente para evitar tales complicaciones. [2]. Con un análisis adecuado de las necesidades los pacientes pueden tener menos riesgos de sufrir complicaciones durante la operación. Asimismo, es importante tener en cuenta el cuidado post operatorio ya que este varía dependiendo de la gravedad del paciente y del conocimiento de los factores de riesgo durante la operación, lo cual es clave para tomar decisiones clínicas en cuanto a la administración de fármacos, el monitoreo de signos vitales y el suministro de medicamentos prescritos. [3]

Cada año se realizan aproximadamente 234 millones de cirugías mayores en todo el mundo, y cerca de 1.6 millones de personas fallecen como consecuencia. [4] En el caso de

Perú, también se cuenta con esta problemática y las cirugías que cuenta con mayor riesgo postoperatorio son las cirugías abdominales con una tasa de mortalidad a corto plazo que oscila entre el 15% y el 20%, siendo solo superada por la cirugía aórtica de emergencia [5][6]. Actualmente la Inteligencia Artificial (IA), se ha aplicado de diversas formas en el ámbito médico para ayudar en el diagnóstico y prevención de enfermedades [7]. Por ello, la IA también puede ser utilizada para la predicción de complicaciones postoperatorias y así disminuir los casos de enfermedad, la mortalidad y los costos de atención médica en hospitales y el lapso de internación hospitalaria, mejorando los resultados de los pacientes sometidos a cirugía. [8][9]

Para poder generar un modelo de IA, es necesario contar con una gran base de datos que esté verificada y sea de confianza. De esta manera, se podrá obtener modelos predictivos basados en el aprendizaje automático. Actualmente, se cuenta con una base de datos de investigación colaborativa llamado INSPIRE, el cual será de gran ayuda para desarrollar los modelos propuestos. [10] Finalmente, el objetivo de este proyecto es analizar qué factores, durante las operaciones de abdomen, producen que los pacientes vayan a UCI a través de modelos de clasificación usando inteligencia artificial; así como, predecir la duración de la estancia.

II. METODOLOGÍA

En primer lugar, se tuvo que seleccionar los datos de entrada. Luego es necesario pre-procesar esta información de tal forma que no cuente con información no deseada. Por último, se desarrollaron modelos de machine learning para evaluar el impacto de los factores durante las operaciones.

A. Selección y descripción de los datos

La base de datos que se usó fue INSPIRE, a publicly available research dataset for perioperative medicine 1.2 de Physionet. De esta base de datos se extrajo a los pacientes, cuyas operaciones tenían como código 0WJG0 que implican intervenciones en la cavidad peritoneal. De estos pacientes, solo se tomarán aquellos que cuenten con solo una operación realizada.

B. Preprocesamiento

- La información de los pacientes por cada operación se sacó del archivo vitals.csv. En este archivo se seleccionó por cada operación (op_id), los valores medidos como

Identify applicable funding agency here. If none, delete this.

¹ Estudiante Pregrado de Especialidad de Ingeniería Biomédica Universidad Peruana Cayetano Heredia, Lima, Perú.

² Estudiante Pregrado de Especialidad de Ingeniería Biomédica Pontificia Universidad Católica del Perú, Lima, Perú.

ritmo cardiaco (hr), frecuencia respiratoria (rr), perdida de sangre estimada (ebl), presión arterial media (art_mbp), etc. Los promedios por cada valor se almacenaron en un archivo aparte.

- El target a clasificar fue obtenido del archivo operations.csv. De este archivo, se filtro los datos en base al procedimiento a analizar mencionado y se extrajo la probabilidad de entrar a UCI en formato binario.
- La ultima etapa del preprocesamiento fue la limpieza de los datos. En este caso, se retiro a los pacientes que tenían más de dos operación. Además, se elimino las columnas tenían más de 400 datos faltantes. De igual forma, se eliminó las filas que presentaban valores atípicos.

C. Modelos de aprendizaje

Para desarrollar nuestros modelos, se dividió aleatoriamente el conjunto de datos en un 75% para el entrenamiento y un 25% para la prueba. Utilizamos el conjunto de entrenamiento para alimentar ocho modelos de aprendizaje automático importados de la biblioteca scikit-learn. Estos modelos fueron seleccionados según su frecuencia de uso, y para cada uno se utilizaron los parámetros predeterminados. Los clasificadores aplicados fueron: Regresión Logística, K-Vecinos Más Cercanos, Máquina de Vectores de Soporte, Árbol de Decisión, Bosque Aleatorio y Extreme Gradient Boosting.

III. RESULTADOS

Las siguientes tablas presentan los resultados de los clasificadores implementados para 4 casos distintos: tomando los datos de acelerometría solo de la muñeca; de la muñeca y el tobillo derecho; de la muñeca, el tobillo derecho y la cadera; y de la muñeca, el tobillo derecho, el tobillo izquierdo y la cadera.

REFERENCES

Please number citations consecutively within brackets [1]. The sentence punctuation follows the bracket [2]. Refer simply to the reference number, as in [3]—do not use “Ref. [3]” or “reference [3]” except at the beginning of a sentence: “Reference [3] was the first . . .”

Number footnotes separately in superscripts. Place the actual footnote at the bottom of the column in which it was cited. Do not put footnotes in the abstract or reference list. Use letters for table footnotes.

Unless there are six authors or more give all authors’ names; do not use “et al.”. Papers that have not been published, even if they have been submitted for publication, should be cited as “unpublished” [4]. Papers that have been accepted for publication should be cited as “in press” [5]. Capitalize only the first word in a paper title, except for proper nouns and element symbols.

For papers published in translation journals, please give the English citation first, followed by the original foreign-language citation [6].

REFERENCES

- [1] G. Eason, B. Noble, and I. N. Sneddon, “On certain integrals of Lipschitz-Hankel type involving products of Bessel functions,” *Phil. Trans. Roy. Soc. London*, vol. A247, pp. 529–551, April 1955.
- [2] J. Clerk Maxwell, *A Treatise on Electricity and Magnetism*, 3rd ed., vol. 2. Oxford: Clarendon, 1892, pp.68–73.
- [3] I. S. Jacobs and C. P. Bean, “Fine particles, thin films and exchange anisotropy,” in *Magnetism*, vol. III, G. T. Rado and H. Suhl, Eds. New York: Academic, 1963, pp. 271–350.
- [4] K. Elissa, “Title of paper if known,” unpublished.
- [5] R. Nicole, “Title of paper with only first word capitalized,” *J. Name Stand. Abbrev.*, in press.
- [6] Y. Yorozu, M. Hirano, K. Oka, and Y. Tagawa, “Electron spectroscopy studies on magneto-optical media and plastic substrate interface,” *IEEE Transl. J. Magn. Japan*, vol. 2, pp. 740–741, August 1987 [Digests 9th Annual Conf. Magnetism Japan, p. 301, 1982].
- [7] M. Young, *The Technical Writer’s Handbook*. Mill Valley, CA: University Science, 1989.